



基于一种新的F-YOLO深度网络 的城市植被覆盖研究

吴迪 徐昇

南京林业大学 信息科学技术学院

二〇二二年十一月

目 录



第一章 研究背景



第二章 研究方法



第三章 研究结果



第四章 参考文献



第一章

研究背景

第一章 | 研究背景

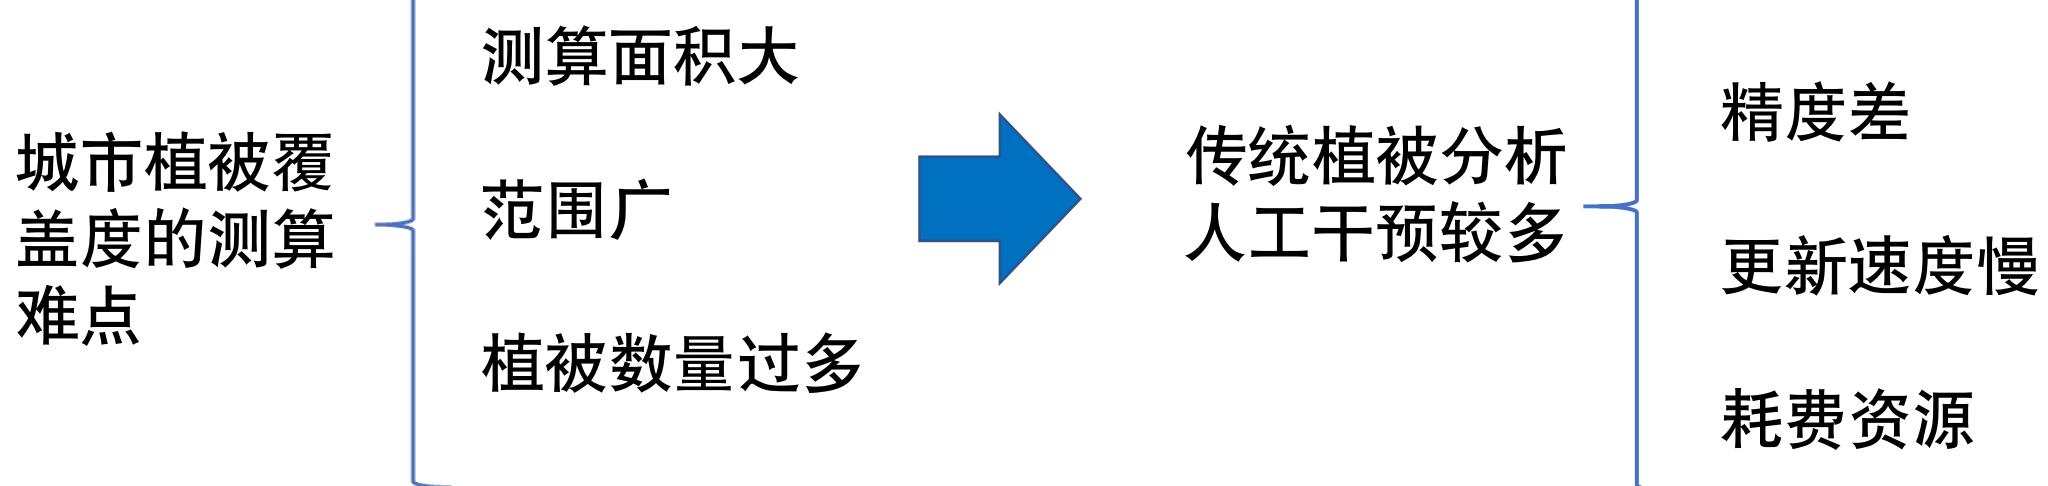
城市的植被覆盖度是衡量城市发展的一个重要参数

- 体现了一个区域的绿化程度
- 决定了城市的绿色规划及其发展方向



第一章 | 研究背景

需要更加智能化的方法来对植被覆盖进行研究



目前的城市植被覆盖度测算技术

传统的地面监测方法

目测
仪器
模型



遥感具有数据采集范围广泛、能够持续监测目标区域的优点，可获取不同尺度上的植被覆盖及其变化信息

在采用遥感图像技术来统计覆盖度时，
关键难点就是图像中目标的检测、定位和分割。

目前的图像分割方法

- 传统图像分割法：包括基于阈值、边缘、区域、聚类及特定理论图像分割等方法
- 基于深度学习的分割方法



图像分割任务的要求和复杂性增加

- 基于特定理论的分割方法：如基于遗传理论的分割方法、基于小波变换的分割方法、基于支持向量机的分割方法等。

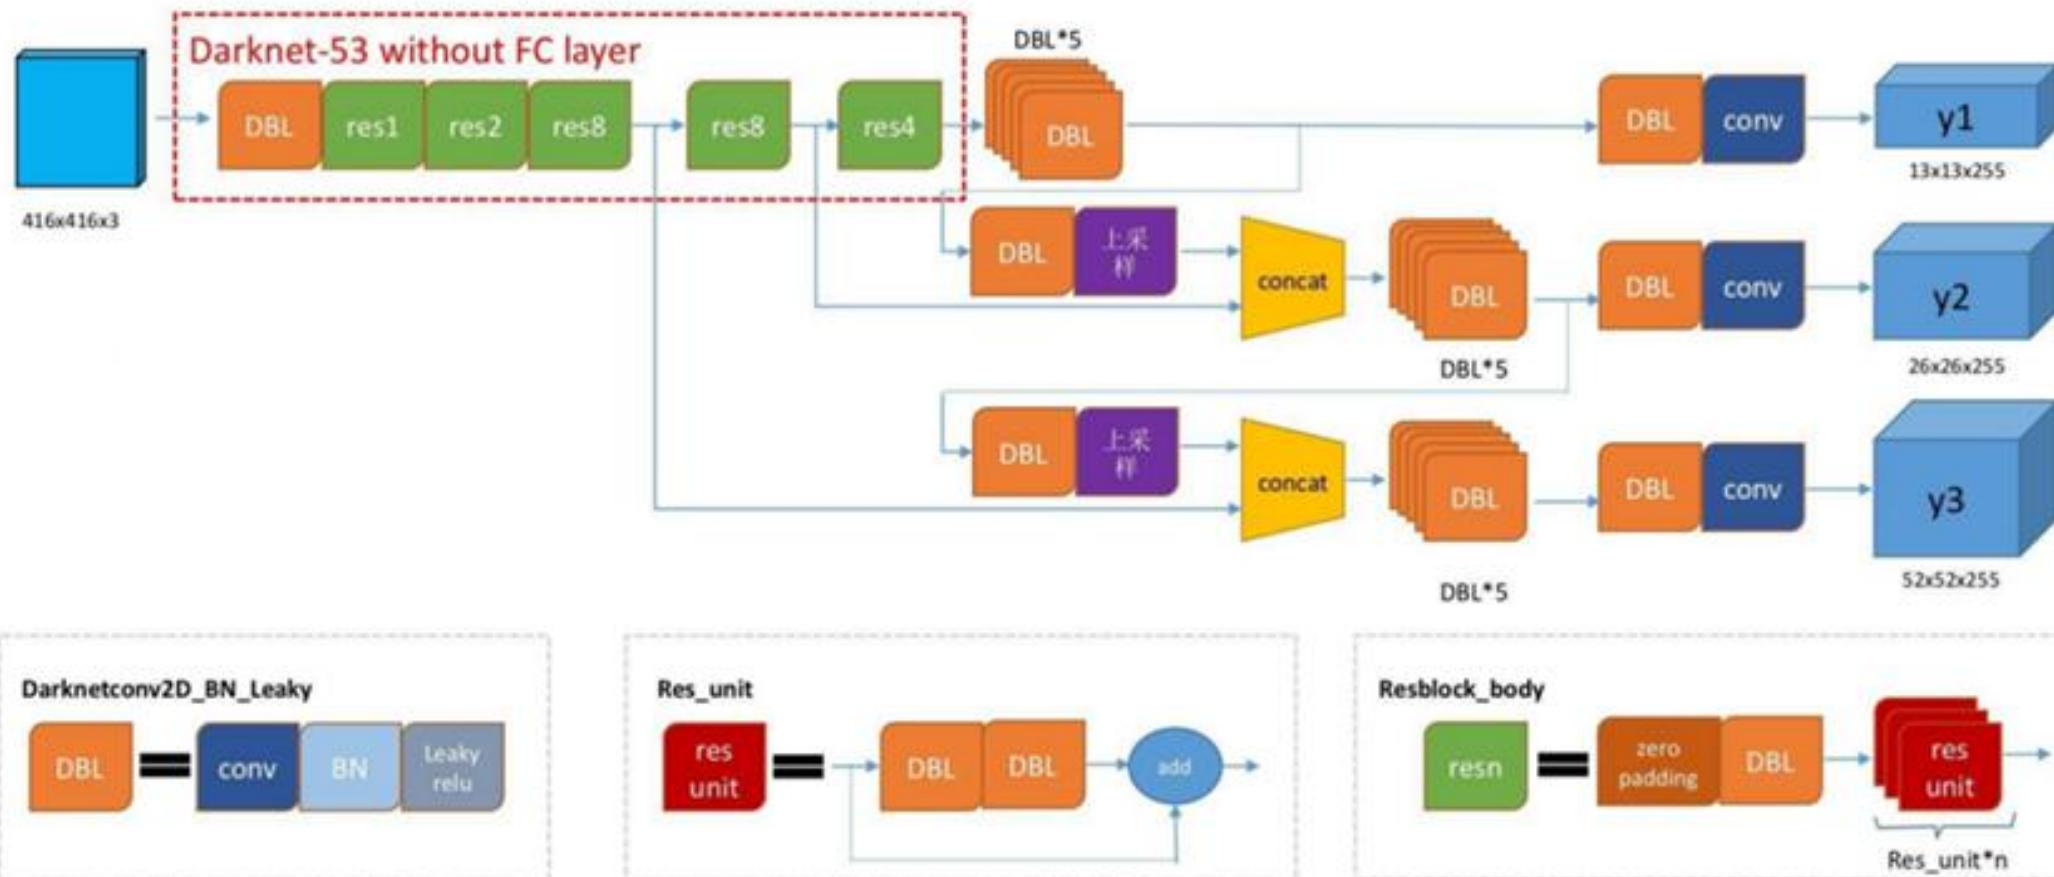


第二章

研究方法

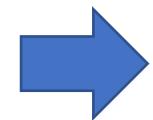
第二章 | 研究方法

F-YOLO中检测部分网络结构图



第二章 | 研究方法

得到特征图



将输出的结果进行解码

物体中心距离网格左上角位置的预测偏移量

预测框的中心横
纵坐标与高宽

先验框的高和
宽

$$\begin{aligned} b_x &= (\text{sigmoid}(t_x) + c_x) \times \text{stride} \\ b_y &= (\text{sigmoid}(t_y) + c_y) \times \text{stride} \\ b_w &= p_w e^{t_w} \times \text{stride} \\ b_h &= p_h e^{t_h} \times \text{stride} \\ \text{conf} &= \text{sigmoid}(\text{raw_conf}) \\ \text{prob} &= \text{sigmoid}(\text{raw_prob}) \end{aligned}$$

网格左上角的
坐标

物体相对于先验
框的预测偏移量

最后特征图
的缩放比例

第二章 | 研究方法

3. 后处理将预测结果原图片中



4. 筛选出类别置信度小于阈值的预测框



5. 进行非极大值抑制



6. 框体计算IOU (Intersection over Union) 值，实验中当IOU值大于设定的
阈值时，该框体对应的权重将会置0

第二章 | 研究方法

算法在目标框坐标回归过程中采用的是均方误差损失函数，
在类别和置信度上使用了交叉熵作为损失函数。

目标物体的中心坐标的误差 → $A = \lambda_0 \sum_{i=0}^{s^2} \sum_{j=0}^B I_{ij}^{obj} [(x_i - x_t^j)^2 + (y_i - y_t^j)^2]$

目标物体的宽高坐标差 → $B = \lambda_0 \sum_{i=0}^{s^2} \sum_{j=0}^B I_{ij}^{obj} [(\frac{w_i}{w_t^j})^2 + (\frac{h_i}{h_t^j})^2]$

LOSS=A+B-C-D-E

目标物体置信度的误差 → $C = \sum_{i=0}^{s^2} \sum_{j=0}^B I_{ij}^{obj} [\mathbb{C}_t^j \log(C_i^j) + (1 - \mathbb{C}_t^j) \log(1 - C_i^j)]$

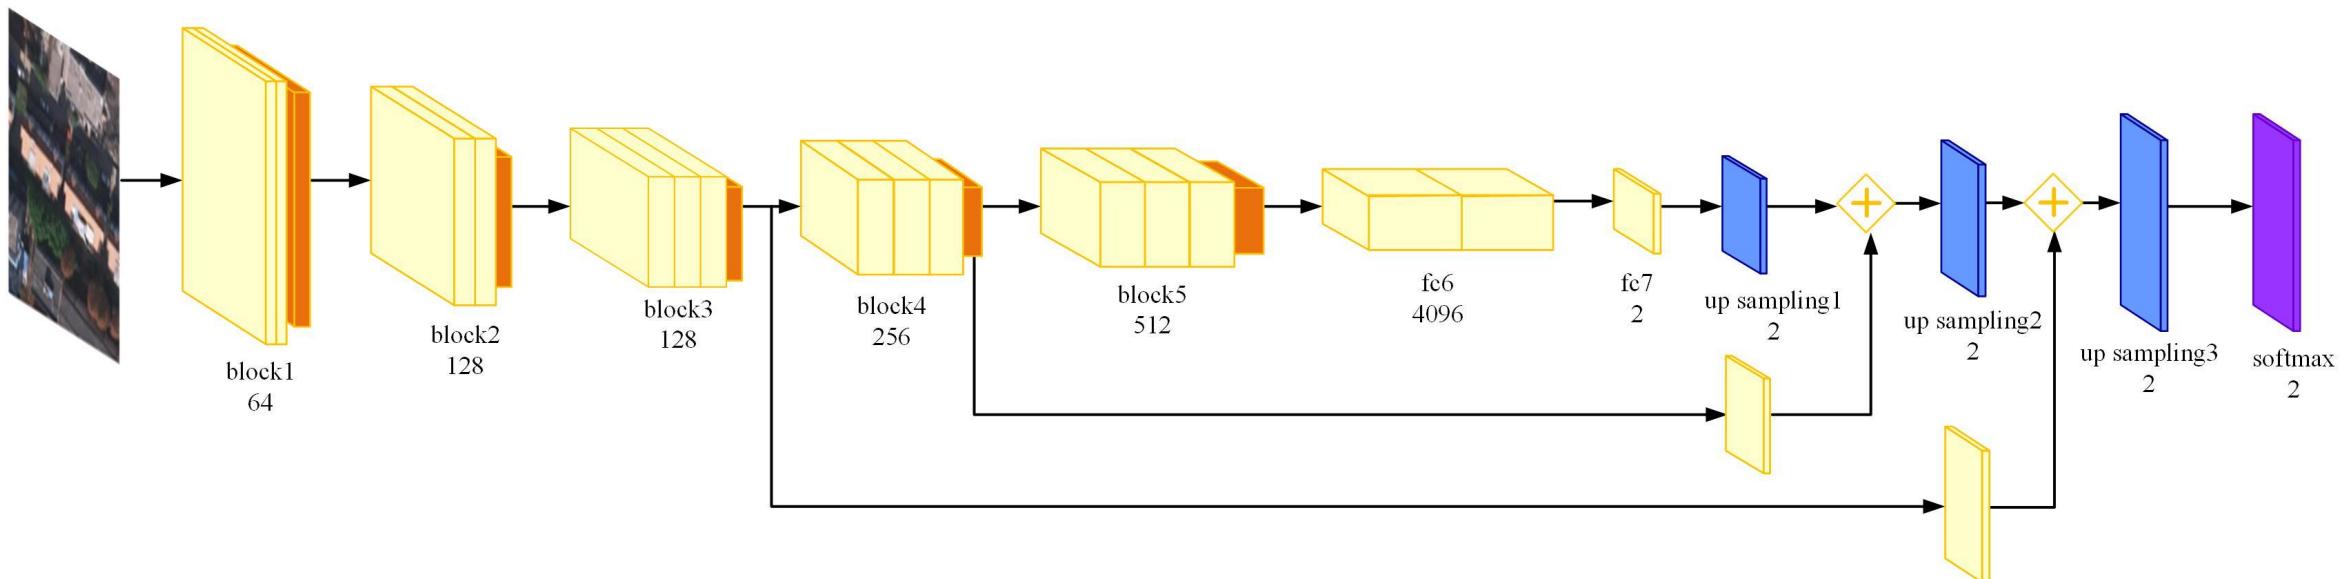
目标物体的分类误差 → $D = \lambda_4 \pi_{III} \sum_{i=0}^{s^2} \sum_{j=0}^B I_{ij}^{noobj} [\mathbb{C}_t^j \log(C_i^j) + (1 - \mathbb{C}_t^j) \log(1 - C_i^j)]$

$\lambda_c = \frac{1}{N} \sum_{i^2+j^2 < r^2} \sum_{j=0}^s I_{ij} \cdot C$ → $E = \sum_{i=0}^{s^2} \lambda_c \cdot I_{III}^{-\pi_{III}} \sum_{c \in class} [\mathbb{P}_t^j \log(P_i^j) + (1 - \mathbb{P}_t^j) \log(1 - P_i^j)]$

第二章 | 研究方法

F-YOLO中语义分割部分模型

新的F-YOLO网络基于FCN-8模型，将带有语义的彩色分割图像转化成 $n\text{Classes} \times W \times H$ 的标签，标签由0和1组成，一个通道代表一个类别，不同通道的同一位置上仅有一个1，表示此像素的正确分类。



- 将CNN中紧跟在卷积和池化层后的全连接层换成 1×1 卷积层，得到多通道的二维降采样的特征图，保留了特征图的二维空间信息，同时使得网络可以接受任意大小的输入，输出同样大小的分割图。
- 通过上采样将特征图还原成原始图像大小，各通道对应位置数值为此像素在各类别上的预测概率，概率的最大值所在通道对应类别为此像素预测类别，从而实现像素级分类。



第三章

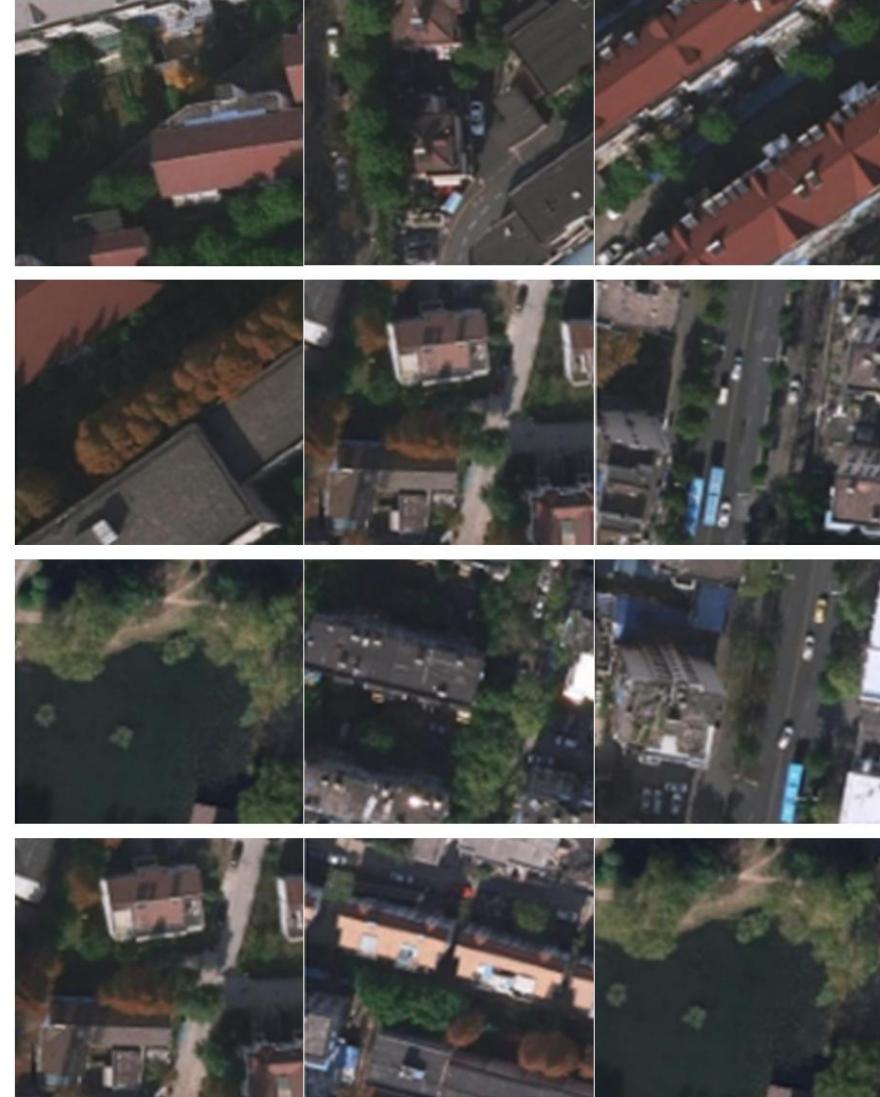
研究结果

第三章 | 研究结果

数据集获取

实验研究对象是南京市紫金山区域的植被。

对获得的遥感正射图像进行分割处理，每张图片的分辨率为 500×500 ，共分割出1500张遥感图像作为数据集。



第三章 | 研究结果

标注的数据集



训练过程中，训练集，测试集和验证集比例是7: 2: 1，在神经网络训练过程中，通过监测LOSS值来确定最优学习参数。LOSS值会逐渐下降致收敛，此时输出最后参数。

第三章 | 研究结果

不同区域地段的植被检测情况

- 能够完整的识别出某一区域内的树木。
- 对于乔木、灌木等多种类型的植被都有较高的检测精度。
- 对于有建筑物遮挡的植被，其识别结果的精度也较高。
- 但对于一些光线较暗、植被本身颜色较深等情况存在误差。
- 精度评估中，实际植被数目3685棵，监测到的植被3598棵，TP值为3502，FP为96，FN为133。



第三章 | 研究结果

从准确率P、召回率R、F值方面对算法进行评价

$$P = \frac{TP}{TP + FP}$$

$$R = \frac{TP}{TP + FN}$$

$$F = \frac{2PR}{P + R}$$

TP: 实际属于植被，并且正确识别为植被

FN: 实际属于植被，但没有被正确识别为植被

FP: 实际不属于植被，但被识别为植被

F是在准确率P和召回率R出现矛盾时，综合考虑二者，用于评价的一个指标。

第三章 | 研究结果

从准确率P、召回率R、F值方面对算法进行评价

方法	召回率R/%	准确率P/%	F/%	主干网络
本文	97.33	96.34	96.83	Darknet-53
SSD	88.25	89.11	88.68	VGG-16
Faster-RCNN	90.52	90.67	90.46	VGG-16

第三章 | 研究结果

对像素级实验结果进行评估

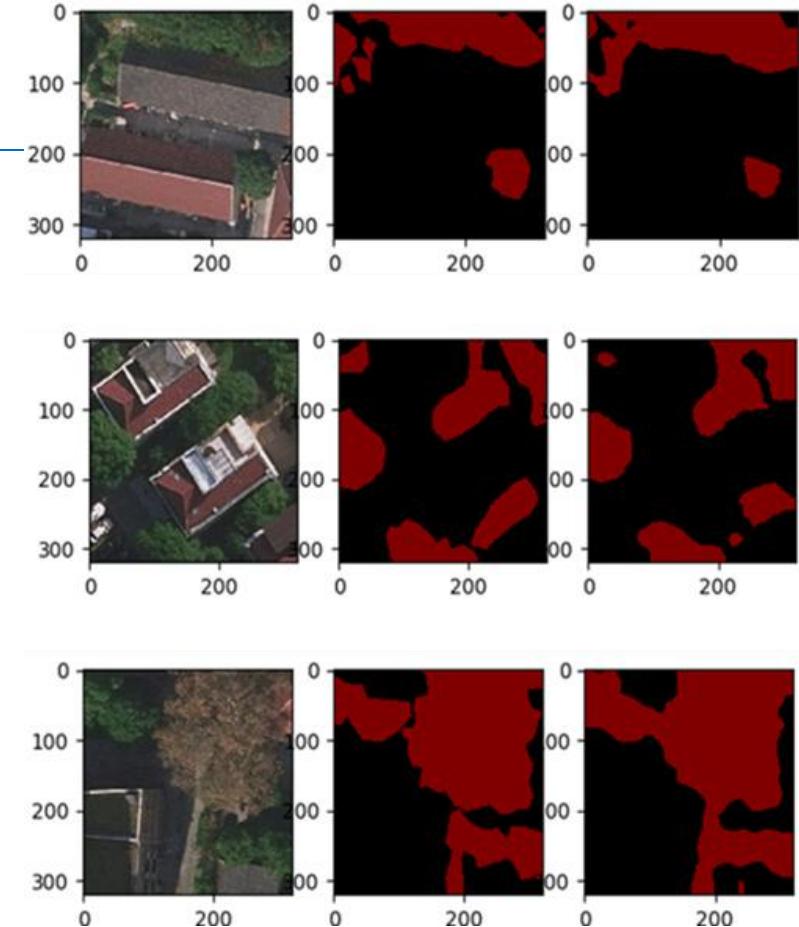
模型	像素精确率(%)
本文	94.76
FCN-16	93.15
U-Net	91.75
FCN-32	83.86

第三章 | 研究结果

从植被覆盖度的测算结果对算法进行评价

$$FVC = \frac{\sum_{i=1}^n l_k \times w_k}{L \times W}$$

方法	植被覆盖度/%	精确度/%
本文	7.83	96.72
目估法	6.54	85.62
仪器法	7.12	92.34





第四章

研究总结

本文算法的创新点与优点

1. 本文基于YOLO网络框架，修改了损失函数来应对遥感数据中的植被复杂多变情况，提出了一种新的F-YOLO网络来对城市植被覆盖度进行研究。
2. 开发出一种像素级的端到端的基于全卷积神经网络的城市区域植被提取方法，以提高城市植被信息化程度。选取FCN-8模型作为本文实验的网络结构。
3. 最后在数据集上训练模型并得到预测结果。针对转置卷积随机化参数，训练速度慢的问题，利用双线性插值法对特征图进行放大，优化训练速度。
4. 实验中将本文提出的改进F-YOLO模型与FCN-32、FCN-16和U-Net模型的实验结果进行对比，结果表明改进的模型在此数据集上的成绩要优于其他模型，达到了94.76%的精确度，而植被覆盖度测算的精确度达到96.72%。

本文算法的可改进点

1. 分割结果还不够精细，上采样结果较为模糊和平滑、没有充分考虑像素与像素之间的关系。
2. 忽略了在通常的基于像素分类的分割方法中使用的空间规整步骤，缺乏空间一致性。在未来的工作中考虑加入条件随机场。
3. 在后端利用条件随机场充分考虑像素与像素之间的关系，对输出结果进行优化。
4. 数据集方面，实验使用的图像数据大多为光线较好、清晰度较高的图像，对于在光线较暗、清晰度较低的环境植被的检测识别仍需要进一步的优化。
5. 如果图像分辨率过高，那么对小目标检测的精度可能会下降。

序号	参考文献
1	杨超, 邬国锋, 李清泉, 等. 植被遥感分类方法研究进展[J]. 地理与地理信息科学, 2018, 034(004):24-32.
2	张淑梅. 郑州城市森林景观肌理演化过程与调控路径[D]. 河南农业大学, 2022.
3	杨超, 邬国锋, 李清泉, 等. 植被遥感分类方法研究进展[J]. 地理与地理信息科学, 2018, 34(04):24-32.
4	陈程杜, 健民, 杨红艳. 内蒙古荒漠化草原植被高光谱特征提取与分析[J]. 光学仪器, 2018, 40(06): 42-47.
5	Yu Xiaolei, Guo Xulin. Extracting Fractional Vegetation Cover from Digital Photographs: A Comparison of In Situ, SamplePoint, and Image Classification Methods[J]. Sensors, 2021, 21(21): 7310-7310.
6	Robin Wilson. Advanced remote sensing: terrestrial information extraction and applications , by Shunlin Liang, Xiaowen Li and Jindi Wang[J]. International Journal of Remote Sensing, 2013, 34(14).
7	Andreas Kamilaris, Francesc X. Prenafeta-Boldú. Deep learning in agriculture: A survey[J]. Computers and Electronics in Agriculture, 2018, 147.

序号	参考文献
8	Wu Dong, Dili Peng, Xu Liu, et al. Eight Direction Improved Sobel Algorithm Based on Morphological Processing in 5G Smart Grid[C]. Proceedings of 2021 2nd International Conference on Computing, Networks and Internet of Things, 2021: 184-188.
9	谷昱良, 翟旭明. 基于小波变换的权重自适应图像分割模型[J]. 图学学报, 2020, v.41;No.153(05):49-55.
10	Chen Guanzhou, Tan Xiaoliang, Guo Beibei, et al. SDFCNv2: An Improved FCN Framework for Remote Sensing Images Semantic Segmentation[J]. Remote Sensing, 2021, 13(23): 4902-4902.
11	Badrinarayanan Vijay, Kendall Alex, Cipolla Roberto.SegNet: A Deep Convolutional Encoder-Decoder Architecture for Image Segmentation.[J]. IEEE transactions on pattern analysis and machine intelligence,2017,39(12).
12	Jozdani Shahab, Chen Dongmei, Pouliot Darren, et al. A review and meta-analysis of generative adversarial networks and their applications in remote sensing[J]. International Journal of Applied Earth Observation and Geoinformation, 2022, 108.
13	徐杰. 基于超图融合语义信息的图像场景分类方法[D]. 北京交通大学, 2014.
14	李国进, 黄晓洁, 李修华. 基于改进YOLOv3的树上成熟芒果检测方法[J]. 沈阳农业大学学报, 2021, 52(01):70-78.



恳请专家批评指正

THANK YOU!

汇报人 | 吴迪